

Maestría en Analítica e Inteligencia de Negocios

Clase: Series de tiempo y pronóstico

PhD. St. Orlando Joaqui-Barandica

Universidad del Valle

2021

Contenido

- 1 Introducción**
- 2 Gráficos de series de tiempo**
- 3 Autocorrelación - ACF**
- 4 Ruido Blanco**

Contenido

1 Introducción

2 Gráficos de series de tiempo

3 Autocorrelación - ACF

4 Ruido Blanco

¿Qué se puede pronosticar?

Se requieren **pronósticos** en muchas situaciones:

- Decidir si se construirá otra planta de generación de energía en los próximos cinco años requiere pronósticos de la demanda futura.
- Programar el personal en un centro de llamadas la próxima semana requiere pronósticos de volúmenes de llamadas.
- Almacenar un inventario requiere pronósticos de los requisitos de stock. Se pueden requerir pronósticos con varios años de anticipación (para el caso de inversiones de capital), o solo unos minutos antes (para el enrutamiento de telecomunicaciones).

¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.

¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



¿Qué se puede pronosticar?

Cualesquiera que sean las circunstancias o los horizontes de tiempo involucrados, el pronóstico es una ayuda importante para una planificación efectiva y eficiente.



Predicción de series de tiempo

Al pronosticar datos de series temporales, el objetivo es estimar cómo la secuencia de observaciones continuará en el futuro.

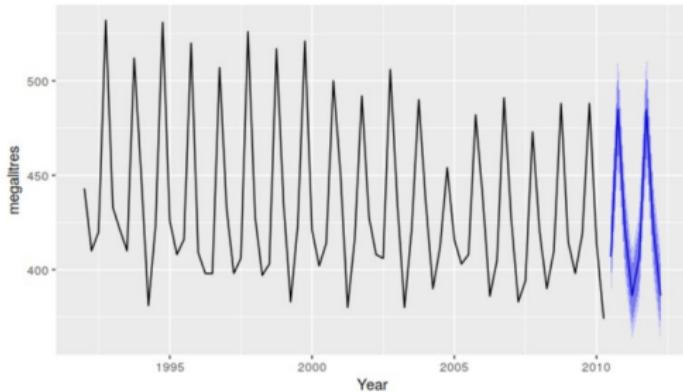
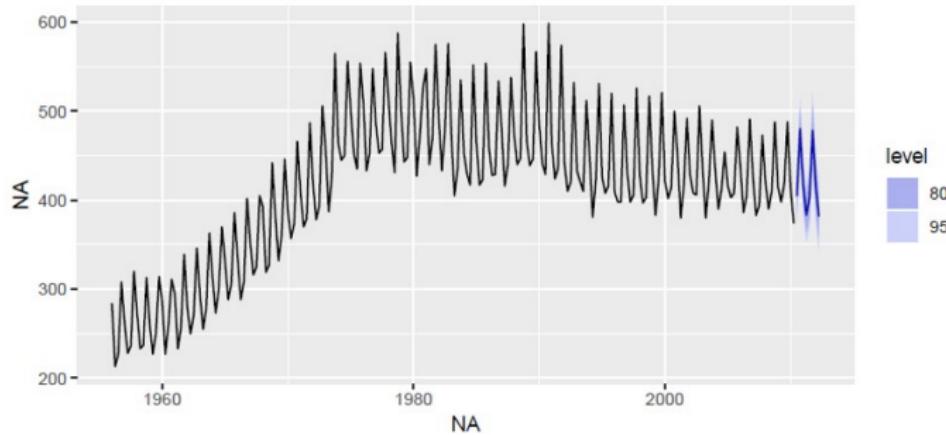


Figura 1.1: Producción de cerveza trimestral en Australia: 1992T1-2010T2, con dos años de pronósticos.

- Observe cómo los pronósticos capturaron el patrón estacional visto en los datos históricos y lo replicaron durante los próximos dos años.
- La región sombreada muestra intervalos de predicción del 80 %. Es decir, se espera que cada valor futuro se encuentre en la región sombreada con una probabilidad del 80 %.

Predicción de series de tiempo

Al pronosticar datos de series temporales, el objetivo es estimar cómo la secuencia de observaciones continuará en el futuro.



Predicción de series de tiempo

Los métodos de predicción de series de tiempo más simples utilizan solo información sobre la variable a pronosticar y no intentan descubrir los factores que afectan su comportamiento.

Por lo tanto, extrapolarán tendencias y patrones estacionales, pero **ignorarán** toda otra información, como iniciativas de marketing, actividad de la competencia, cambios en las condiciones económicas, etc.

**Los modelos de series de tiempo utilizados para el pronóstico incluyen
modelos de descomposición, modelos de suavizado exponencial y modelos
ARIMA**

Pasos para el pronóstico

1. Paso 1: Definición del problema.

La definición cuidadosa del problema requiere una comprensión de la forma en que se utilizarán los pronósticos, quién los requiere y cómo se ajusta la función de pronóstico dentro de la organización que los requiere

2. Paso 2: Recopilación de información.

Siempre se requieren al menos dos tipos de información: **(a)** datos estadísticos, y **(b)** la experiencia acumulada de las personas que recopilan los datos y utilizan los pronósticos.

Pasos para el pronóstico

3. Paso 3: Análisis preliminar (exploratorio).

Comience siempre graficando los datos.

- ¿Hay patrones consistentes?
- ¿Hay una tendencia significativa?
- ¿Es importante la estacionalidad?
- ¿Hay evidencia de la presencia de ciclos económicos?
- ¿Hay valores atípicos en los datos que deben ser explicados por aquellos con conocimiento experto?
- ¿Qué tan fuertes son las relaciones entre las variables disponibles para el análisis?

Pasos para el pronóstico

4. Paso 4: Elección y ajuste de modelos.

El mejor modelo a utilizar depende de la disponibilidad de datos históricos, la fuerza de las relaciones entre la variable de pronóstico y cualquier variable explicativa, y la forma en que se usarán los pronósticos.

- Modelos de regresión
- Métodos de suavizado exponencial
- Modelos ARIMA de Box-Jenkins
- Modelos de regresión dinámica
- Pronóstico jerárquico
- Redes neuronales y autorregresión vectorial
- ...

Pasos para el pronóstico

5. Paso 5: Uso y evaluación de un modelo de pronóstico.

Una vez que se ha seleccionado un modelo y se han estimado sus parámetros, el modelo se usa para hacer pronósticos. El rendimiento del modelo solo puede evaluarse adecuadamente después de que los datos para el período de pronóstico estén disponibles.

Se han desarrollado varios métodos para ayudar a evaluar la precisión de los pronósticos.

La perspectiva del pronóstico estadístico

¿Es el pronóstico una variable aleatoria?

La perspectiva del pronóstico estadístico

¿Es el pronóstico una variable aleatoria?

Lo que estamos tratando de pronosticar es desconocido (o no lo estaríamos pronosticando), por lo que podemos pensar en él como una **variable aleatoria**.

Por ejemplo, las ventas totales para el próximo mes podrían tomar un rango de valores posibles, y hasta que sumemos las ventas reales al final del mes, no sabemos cuál será el valor. Entonces, hasta que sepamos las ventas para el próximo mes, es una cantidad aleatoria.

La perspectiva del pronóstico estadístico

En la mayoría de las situaciones de pronóstico, la variación asociada con lo que pronosticamos se reducirá a medida que se aproxime el evento. En otras palabras, cuanto más adelante pronostiquemos, más inseguros estaremos.

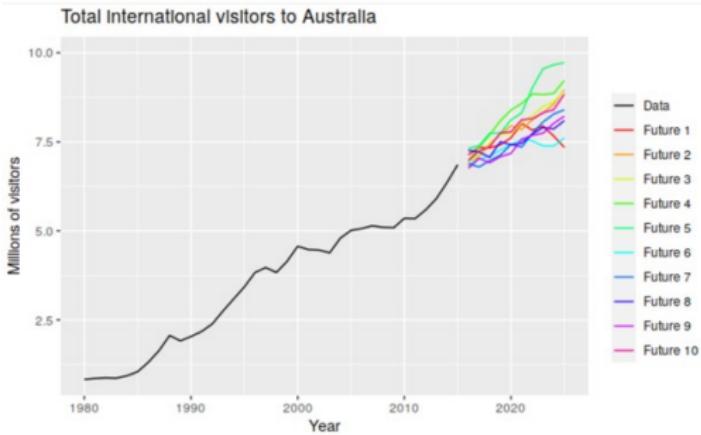


Figura 1.2: Total de visitantes internacionales a Australia (1980-2015) junto con diez posibles futuros.

La perspectiva del pronóstico estadístico

La siguiente gráfica muestra intervalos de 80 % y 95 % para los futuros visitantes internacionales australianos. La línea azul es el promedio de los posibles valores futuros, que llamamos pronósticos puntuales .

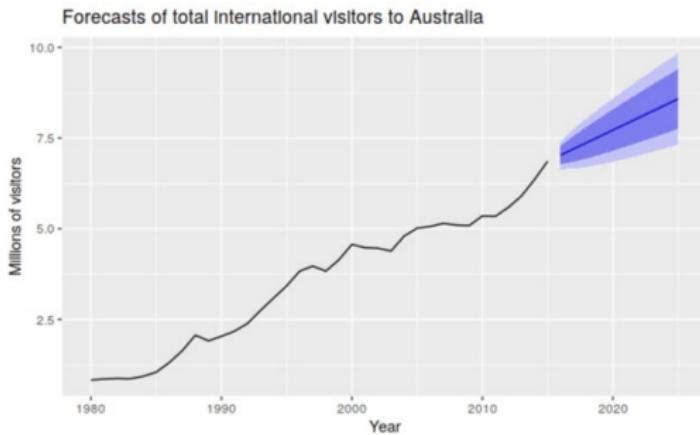


Figura 1.3: Total de visitantes internacionales a Australia (1980–2015) junto con pronósticos de 10

Contenido

1 Introducción

2 Gráficos de series de tiempo

3 Autocorrelación - ACF

4 Ruido Blanco

Gráficos de series de tiempo

Lo primero que debe hacer en cualquier tarea de análisis de datos es trazar los datos. Los gráficos permiten visualizar muchas características de los datos, incluidos patrones, observaciones inusuales, cambios en el tiempo y relaciones entre variables.

Las características que se ven en los gráficos de los datos deben incorporarse, tanto como sea posible, en los métodos de pronóstico que se utilizarán.

Objetos ts

Una serie temporal puede considerarse como una lista de números, junto con información sobre las veces que se registraron esos números. Esta información puede almacenarse como un **ts objeto** en R.

Suponga que tiene observaciones anuales de los últimos años:

Año	Obs
2012	123
2013	39
2014	78
2015	52
2016	110

Objetos ts

```
y <- ts(c(123,39,78,52,110), start=2012)
```

Objetos ts

```
y <- ts(c(123,39,78,52,110), start=2012)
```

Time Series:

Start = 2012

End = 2016

Frequency = 1

```
[1] 123 39 78 52 110
```

Objetos ts

```
y <- ts(c(123,39,78,52,110), start=2012)
```

Time Series:

Start = 2012

End = 2016

Frequency = 1

[1] 123 39 78 52 110

```
y <- ts(c(123,39,78,52,110), start=2003, frequency=12)
```

Objetos ts

```
y <- ts(c(123,39,78,52,110), start=2012)
```

Time Series:

Start = 2012

End = 2016

Frequency = 1

```
[1] 123 39 78 52 110
```

```
y <- ts(c(123,39,78,52,110), start=2003, frequency=12)
```

	Jan	Feb	Mar	Apr	May
2003	123	39	78	52	110

Objetos ts

La **frecuencia** es el número de observaciones antes de que se repita el patrón estacional. Cuando se usa la `ts()` función en R, se deben usar las siguientes opciones.

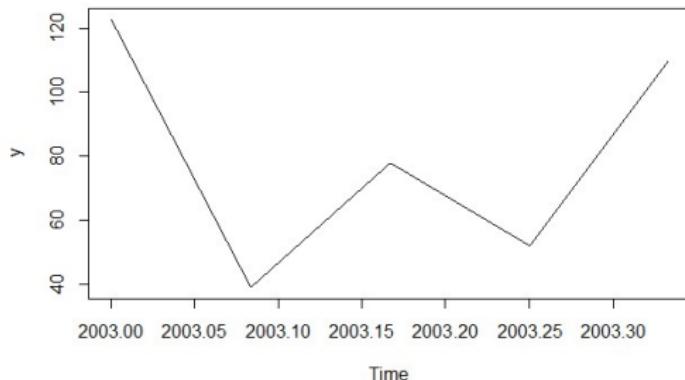
Datos	Frec
Anual	1
Trimestre	4
Mensual	12
Semanal	52

Gráficos de tiempo

```
y <- ts(c(123,39,78,52,110), start=2003, frequency=12)
plot(y)
```

Gráficos de tiempo

```
y <- ts(c(123,39,78,52,110), start=2003, frequency=12)
plot(y)
```



Gráficos de tiempo

Cargar la librería **fpp2**

```
library(fpp2)
```

```
melsyd
```

Gráficos de tiempo

Cargar la librería **fpp2**

```
library(fpp2)
```

```
melsyd
```

Time Series:

Start = c(1987, 26)

End = c(1992, 48)

Frequency = 52

	First.Class	Business.Class	Economy.Class
1987.481	1.912	NA	20.167
1987.500	1.848	NA	20.161
1987.519	1.856	NA	19.993
1987.538	2.142	NA	20.986
1987.558	2.118	NA	20.497
1987.577	2.048	NA	20.770
1987.596	2.111	NA	21.111
1987.615	2.199	NA	20.675
1987.635	2.231	NA	22.092
1987.654	2.081	NA	20.772

Gráficos de tiempo

La librería **fpp2** carga:

- Algunos datos que usaremos en ejemplos y ejercicios.
- El paquete **forecast** (Funciones de pronóstico)
- El paquete **ggplot2** (Funciones de gráficos)
- El paquete **fma** (Datos de series de tiempo)
- El paquete **expsmooth** (Datos de series de tiempo)

Gráficos de tiempo

```
plot(melsyd)
```

Gráficos de tiempo

```
plot(melsyd)
```

```
plot(melsyd[, "Economy.Class"])
```

Gráficos de tiempo

```
plot(melsyd)
```

```
plot(melsyd[, "Economy.Class"])
```

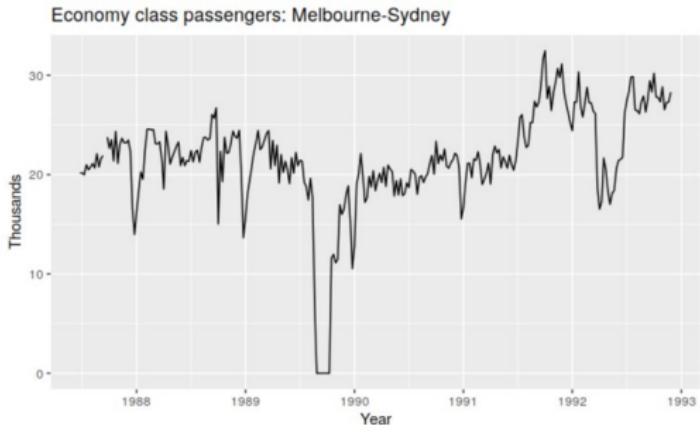
```
autoplot(melsyd[, "Economy.Class"]) +
  ggtitle("Economy class passengers: Melbourne-Sydney") +
  xlab("Year") +
  ylab("Thousands")
```

Gráficos de tiempo

```
plot(melsyd)
```

```
plot(melsyd[, "Economy.Class"])
```

```
autoplot(melsyd[, "Economy.Class"]) +  
  ggtitle("Economy class passengers: Melbourne-Sydney") +  
  xlab("Year") +  
  ylab("Thousands")
```



Gráficos de tiempo

Usaremos la función `autoplot()` con frecuencia. Produce automáticamente un diagrama apropiado de lo que sea que le pase en el primer argumento. En este caso, reconoce `melsyd[, "Economy.Class"]` como una serie de tiempo y produce un diagrama de tiempo.

Gráficos de tiempo

Exploración de los datos

- Hubo un período en 1989 en el que no se transportaron pasajeros, esto se debió a una disputa industrial.
- Hubo un período de carga reducida en 1992. Esto se debió a una prueba en la que algunos asientos de clase económica fueron reemplazados por asientos de clase ejecutiva.
- Se produjo un gran aumento en la carga de pasajeros en la segunda mitad de 1991.
- Hay algunas grandes caídas en la carga al comienzo de cada año. Estos se deben a los efectos de vacaciones.
- Hay una fluctuación a largo plazo en el nivel de la serie que aumenta durante 1987, disminuye en 1989 y aumenta nuevamente durante 1990 y 1991.
- Hay algunos períodos de observaciones faltantes.

Gráficos de tiempo

```
autoplot(a10) +  
  ggtitle("Antidiabetic drug sales") +  
  ylab("$ million") +  
  xlab("Year")
```

Gráficos de tiempo

```
autoplot(a10) +  
  ggtitle("Antidiabetic drug sales") +  
  ylab("$ million") +  
  xlab("Year")
```

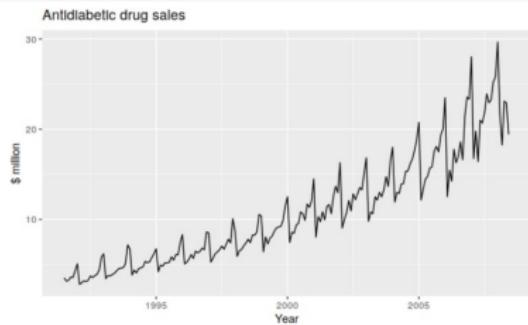


Figura 2.2: Ventas mensuales de medicamentos antidiabéticos en Australia.

Gráficos de tiempo

```
autoplot(a10) +  
  ggtitle("Antidiabetic drug sales") +  
  ylab("$ million") +  
  xlab("Year")
```

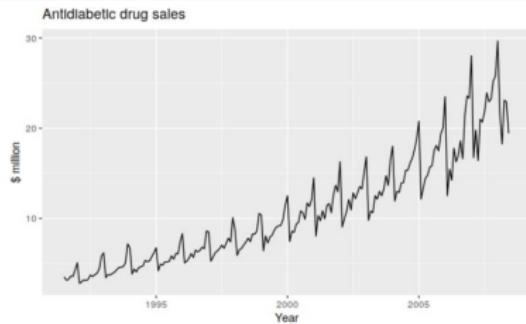


Figura 2.2: Ventas mensuales de medicamentos antidiabéticos en Australia.

Hay una tendencia clara y creciente. Hay un patrón estacional fuerte que aumenta de tamaño a medida que aumenta el nivel de la serie. La caída repentina al comienzo de cada año es causada por un esquema de subsidio del gobierno que hace que sea rentable que los pacientes acumulen medicamentos al final del año calendario

Actividad

- 1 Use `help()` para encontrar información acerca de las series:
 - `dole`
 - `lynx`
 - `goog`
- 2 Cree gráficos de las series anteriores
- 3 Modifique las etiquetas y títulos a los gráficos.

Gráficos de tiempo

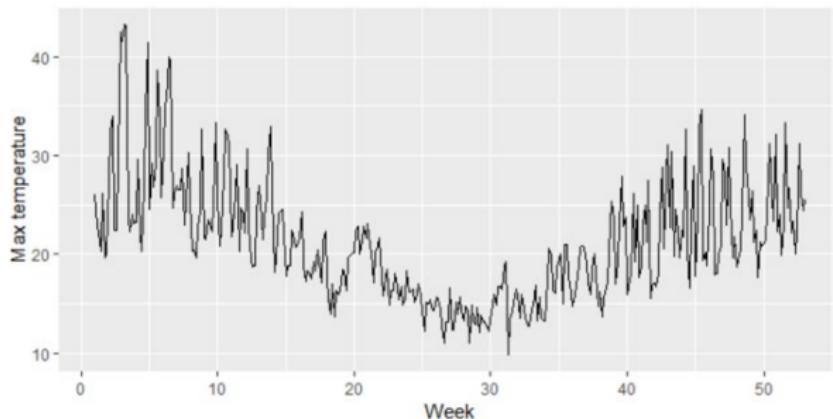
¿Son los gráficos de series de tiempo las mejores representaciones?

```
autoplot(elecdaily[, "Temperature"]) +  
xlab("Week") + ylab("Max temperature")
```

Gráficos de tiempo

¿Son los gráficos de series de tiempo las mejores representaciones?

```
autoplot(elecdaily[, "Temperature"]) +  
xlab("Week") + ylab("Max temperature")
```



Gráficos de tiempo

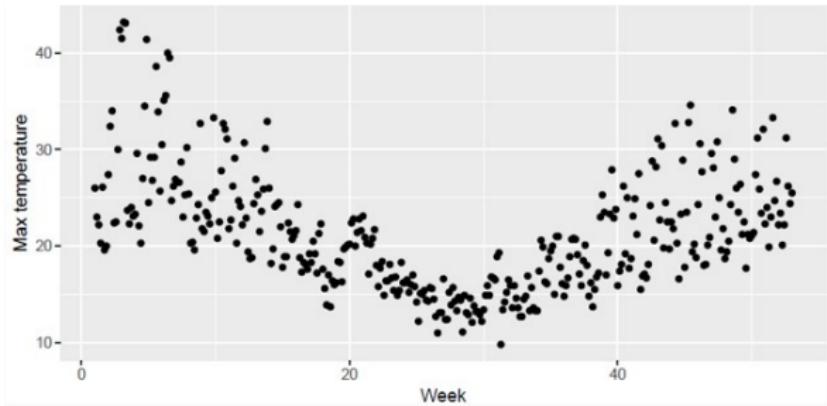
¿Son los gráficos de series de tiempo las mejores representaciones?

```
qplot(time(elecdaily), elecdaily[, "Temperature"]) +  
xlab("Week") + ylab("Max temperature")
```

Gráficos de tiempo

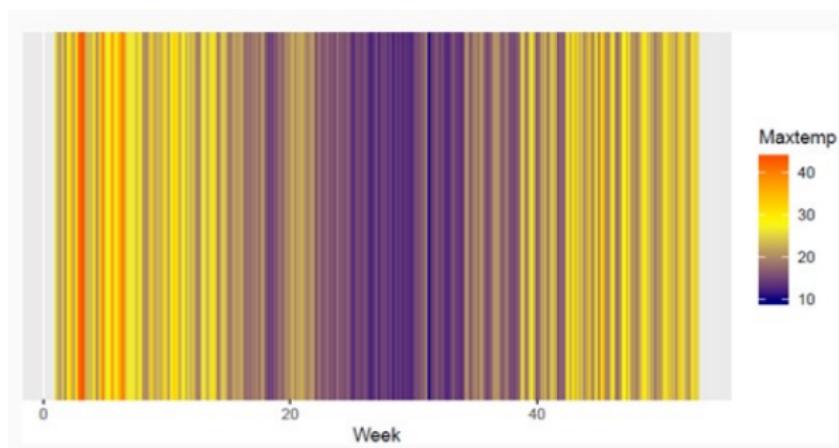
¿Son los gráficos de series de tiempo las mejores representaciones?

```
qplot(time(elecdaily), elecdaily[, "Temperature"]) +  
xlab("Week") + ylab("Max temperature")
```



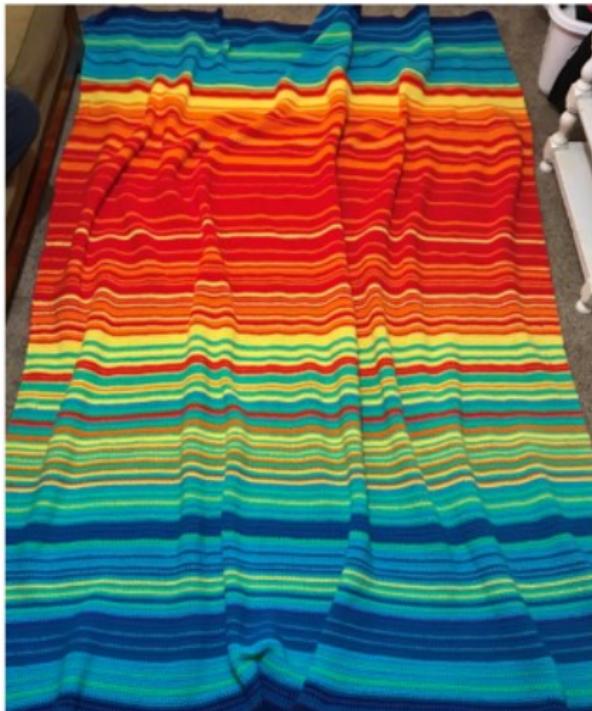
Gráficos de tiempo

¿Son los gráficos de series de tiempo las mejores representaciones?



Gráficos de tiempo

¿Son los gráficos de series de tiempo las mejores representaciones?



Patrones de series de tiempo

Tendencia

Existe una tendencia cuando hay un **aumento o disminución a largo plazo en los datos**. No tiene que ser lineal. A veces nos referiremos a una tendencia como “dirección cambiante”, cuando podría pasar de una tendencia creciente a una tendencia decreciente.

Patrones de series de tiempo

Tendencia

Existe una tendencia cuando hay un **aumento o disminución a largo plazo en los datos**. No tiene que ser lineal. A veces nos referiremos a una tendencia como “dirección cambiante”, cuando podría pasar de una tendencia creciente a una tendencia decreciente.

Estacional

Un patrón estacional ocurre cuando una serie de tiempo se ve afectada por factores estacionales como por ej: la **época del año o el día de la semana** . La estacionalidad es siempre de una frecuencia fija y conocida.

Patrones de series de tiempo

Tendencia

Existe una tendencia cuando hay un **aumento o disminución a largo plazo en los datos**. No tiene que ser lineal. A veces nos referiremos a una tendencia como “dirección cambiante”, cuando podría pasar de una tendencia creciente a una tendencia decreciente.

Estacional

Un patrón estacional ocurre cuando una serie de tiempo se ve afectada por factores estacionales como por ej: la **época del año o el día de la semana** . La estacionalidad es siempre de una frecuencia fija y conocida.

Cíclico

Un ciclo ocurre cuando la exhibición de **datos sube y baja y no son de una frecuencia fija**. Estas fluctuaciones generalmente se deben a las condiciones económicas, y a menudo están relacionadas con el “ciclo económico”.

Patrones de series de tiempo

¿Diferencia entre la estacionalidad y un ciclo?

Patrones de series de tiempo

¿Diferencia entre la estacionalidad y un ciclo?

Si las fluctuaciones no son de una frecuencia fija, entonces son *cíclicas*; Si la frecuencia no cambia y está asociada con algún aspecto del calendario, entonces el patrón es *estacional*.

En general, la duración promedio de los ciclos es más larga que la duración de un patrón estacional, y las magnitudes de los ciclos tienden a ser más variables que las magnitudes de los patrones estacionales.

Ejemplos

¿Qué patrones observa en estas series de tiempo?

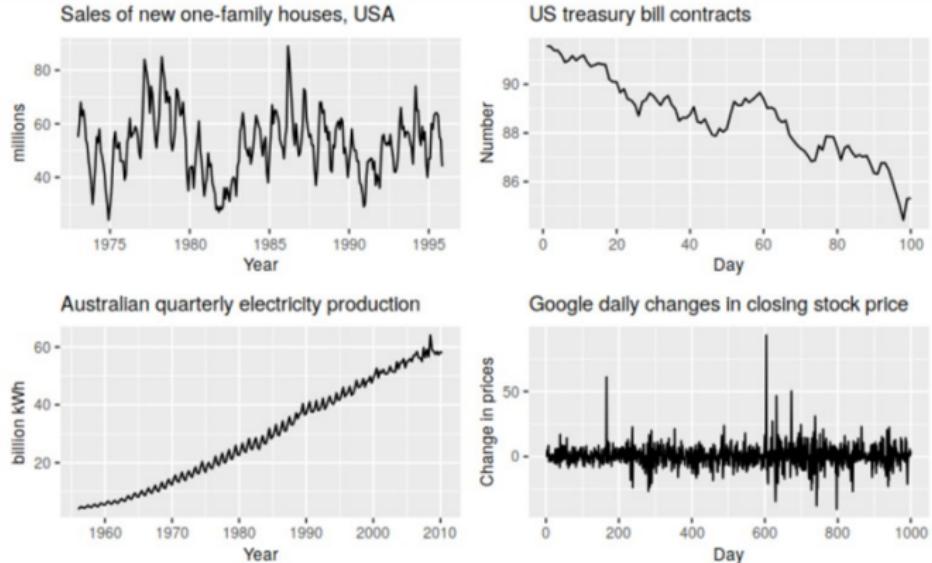


Figura 2.3: Cuatro ejemplos de series de tiempo que muestran diferentes patrones.

Ejemplos

1. Las ventas mensuales de viviendas

- Fuerte estacionalidad dentro de cada año.
- Fuerte comportamiento cíclico con un período de aproximadamente 6-10 años.
- No hay una tendencia aparente en los datos durante este período.

Ejemplos

1. Las ventas mensuales de viviendas

- Fuerte estacionalidad dentro de cada año.
- Fuerte comportamiento cíclico con un período de aproximadamente 6-10 años.
- No hay una tendencia aparente en los datos durante este período.

2. Los contratos de letras del tesoro de los Estados Unidos

- Muestran resultados del mercado de Chicago durante 100 días de negociación consecutivos en 1981.
- No hay estacionalidad, sino una tendencia a la baja evidente.
- Si tuviéramos una serie mucho más larga, veríamos que esta tendencia a la baja es en realidad parte de un ciclo largo, pero cuando se ve en solo 100 días, parece ser una tendencia.

Ejemplos

3. La producción trimestral de electricidad en Australia

- Fuerte tendencia al alza.
- Fuerte estacionalidad.
- No hay evidencia de ningún comportamiento cíclico.

Ejemplos

3. La producción trimestral de electricidad en Australia

- Fuerte tendencia al alza.
- Fuerte estacionalidad.
- No hay evidencia de ningún comportamiento cíclico.

4. El cambio diario en el precio de cierre de las acciones de Google

- No tiene tendencia, estacionalidad o comportamiento cíclico.
- Hay fluctuaciones aleatorias que no parecen ser muy predecibles.
- No hay patrones fuertes que ayuden a desarrollar un modelo de pronóstico.

Diagramas de dispersión

Es útil para explorar las relaciones entre series de tiempo.

```
autoplot(elecemand[,c("Demand","Temperature")], facets=TRUE) +  
  xlab("Year: 2014") + ylab("") +  
  ggtitle("Half-hourly electricity demand: Victoria, Australia")
```

Diagramas de dispersión

Es útil para explorar las relaciones entre series de tiempo.

```
autoplot(elecemand[,c("Demand","Temperature")], facets=TRUE) +  
  xlab("Year: 2014") + ylab("") +  
  ggtitle("Half-hourly electricity demand: Victoria, Australia")
```

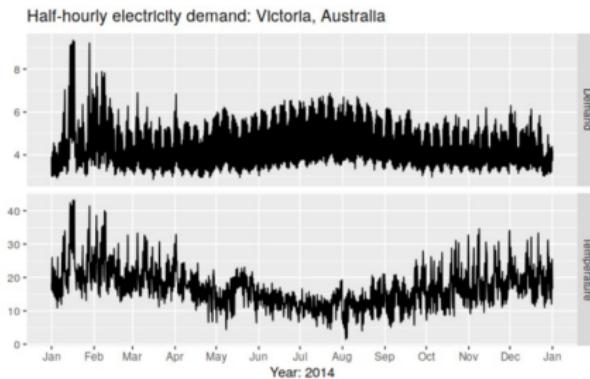


Figura 2.7: Demanda y temperaturas de electricidad cada media hora en Victoria, Australia, para 2014.

Diagramas de dispersión

Podemos estudiar la relación entre la demanda y la temperatura trazando una serie contra la otra.

```
qplot(Temperature, Demand, data=as.data.frame(elecemand)) +  
  ylab("Demand (GW)") + xlab("Temperature (Celsius)")
```

Diagramas de dispersión

Podemos estudiar la relación entre la demanda y la temperatura trazando una serie contra la otra.

```
qplot(Temperature, Demand, data=as.data.frame(elecDemand)) +  
  ylab("Demand (GW)") + xlab("Temperature (Celsius)")
```

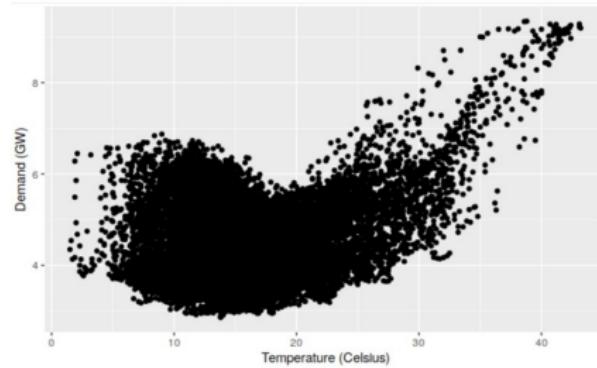


Figura 2.8: Demanda de electricidad de media hora trazada contra la temperatura para 2014 en Victoria, Australia.

Matrices diagramas de dispersión

Considere las cinco series de tiempo, que muestran los números de visitantes trimestrales para cinco regiones de Nueva Gales del Sur, Australia.

```
autoplot(visnights[,1:5], facets=TRUE) +  
  ylab("Number of visitor nights each quarter (millions)")
```

Matrices diagramas de dispersión

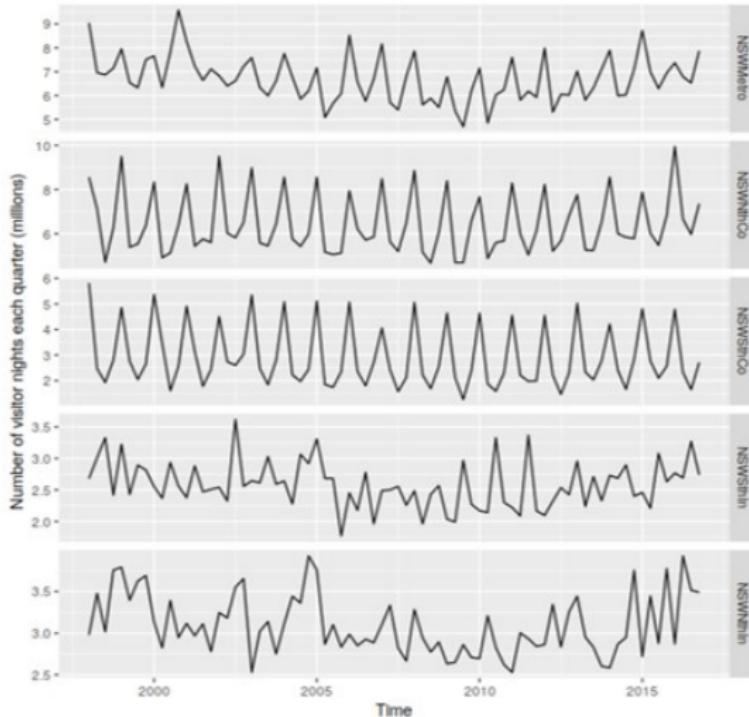


Figura 2.11: Noches trimestrales de visitantes para varias regiones de Nueva Gales del Sur, Australia.

Matrices diagramas de dispersión

```
GGally::ggpairs(as.data.frame(visnights[,1:5]))
```

Matrices diagramas de dispersión

```
GGally::ggpairs(as.data.frame(visnights[,1:5]))
```

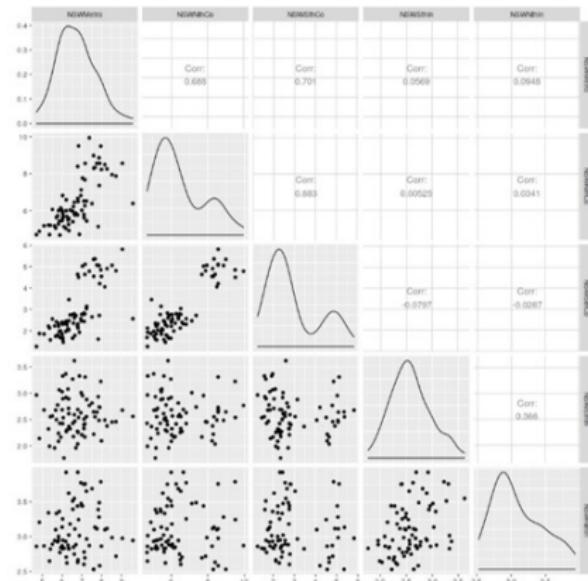


Figura 2.12: Una matriz de diagrama de dispersión de las noches de visitantes trimestrales en cinco regiones de Nueva Gales del Sur, Australia.

Contenido

1 Introducción

2 Gráficos de series de tiempo

3 Autocorrelación - ACF

4 Ruido Blanco

Autocorrelación

Así como la correlación mide el alcance de una relación lineal entre dos variables, la autocorrelación mide la relación lineal entre valores rezagados de una serie de tiempo.

Hay varios coeficientes de autocorrelación correspondientes a cada panel en diagrama de rezagos. Por ejemplo:

- r_1 : Mide la relación entre y_t y y_{t-1}
- r_2 : Mide la relación entre y_t y y_{t-2}
- ...

r_k puede ser escrito como:

$$r_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2},$$

dónde T es la longitud de la serie.

Autocorrelación

A continuación se presentan los primeros nueve coeficientes de autocorrelación para la serie de producción de cerveza.

r_1	r_2	r_3	r_4	r_5	r_6	r_7	r_8	r_9
-0.102	-0.657	-0.060	0.869	-0.089	-0.635	-0.054	0.832	-0.108

Los coeficientes de autocorrelación se trazan para mostrar la función de autocorrelación o ACF. La trama también se conoce como un correlograma.

```
ggAcf(beer2)
```

Autocorrelación

A continuación se presentan los primeros nueve coeficientes de autocorrelación para la serie de producción de cerveza.

r_1	r_2	r_3	r_4	r_5	r_6	r_7	r_8	r_9
-0.102	-0.657	-0.060	0.869	-0.089	-0.635	-0.054	0.832	-0.108

Los coeficientes de autocorrelación se trazan para mostrar la función de autocorrelación o ACF. La trama también se conoce como un correlograma.

```
ggAcf(beer2)
```

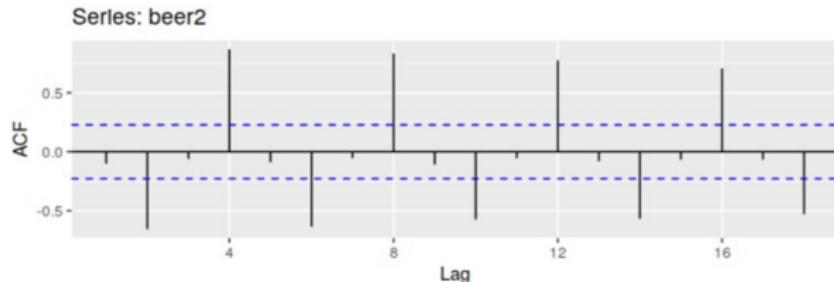


Figura 2.14: Función de autocorrelación de la producción trimestral de cerveza.

Autocorrelación

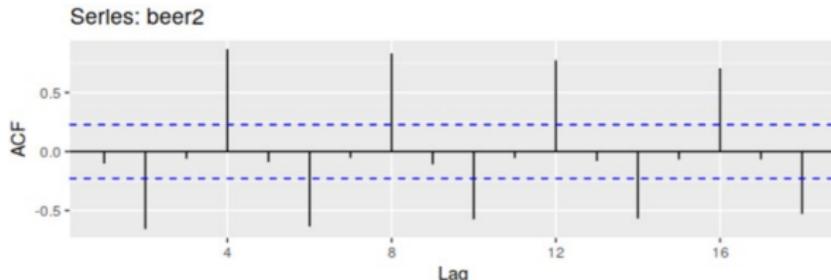


Figura 2.14: Función de autocorrelación de la producción trimestral de cerveza.

- r_4 : Es más alto que los otros rezagos. Esto se debe al patrón estacional en los datos: los picos tienden a estar separados por cuatro cuartos y las caídas tienden a estar separadas por cuatro cuartos.
- r_2 : Es más negativo que los otros rezagos porque los canales o caídas tienden a estar dos cuartos detrás de los picos.
- Las líneas azules discontinuas indican si las correlaciones son significativamente diferentes de cero.

Tendencia y Estacionalidad en ACF

Cuando los datos tienen una **tendencia**

- Las autocorrelaciones para pequeños rezagos tienden a ser grandes y positivas porque las observaciones cercanas en el tiempo también son cercanas en tamaño.
- El ACF de las series temporales con tendencia tiende a tener valores positivos que disminuyen lentamente a medida que aumentan los retrasos.

Tendencia y Estacionalidad en ACF

Cuando los datos tienen una **tendencia**

- Las autocorrelaciones para pequeños rezagos tienden a ser grandes y positivas porque las observaciones cercanas en el tiempo también son cercanas en tamaño.
- El ACF de las series temporales con tendencia tiende a tener valores positivos que disminuyen lentamente a medida que aumentan los retrasos.

Cuando los datos son **estacionales**

- Las autocorrelaciones serán mayores para los rezagos estacionales (en múltiplos de la frecuencia estacional) que para otros rezagos.

Tendencia y Estacionalidad en ACF

Cuando los datos tienen una **tendencia**

- Las autocorrelaciones para pequeños rezagos tienden a ser grandes y positivas porque las observaciones cercanas en el tiempo también son cercanas en tamaño.
- El ACF de las series temporales con tendencia tiende a tener valores positivos que disminuyen lentamente a medida que aumentan los retrasos.

Cuando los datos son **estacionales**

- Las autocorrelaciones serán mayores para los rezagos estacionales (en múltiplos de la frecuencia estacional) que para otros rezagos.

Cuando los datos tienen **tendencia** y son **estacionales**

- Combinación de los efectos anteriores.

Tendencia y Estacionalidad en ACF

```
aelec <- window(elec, start=1980)
autoplot(aelec) + xlab("Year") + ylab("GWh")
```

Tendencia y Estacionalidad en ACF

```
aelec <- window(elec, start=1980)
autoplot(aelec) + xlab("Year") + ylab("GWh")
```

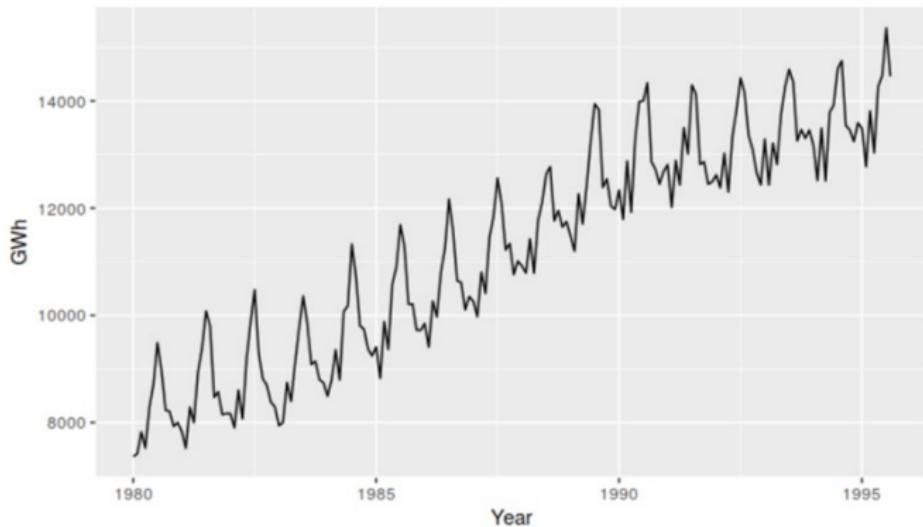


Figura 2.15: Demanda mensual de electricidad en Australia desde 1980-1995.

Tendencia y Estacionalidad en ACF

```
ggAcf(aelec, lag=48)
```

Tendencia y Estacionalidad en ACF

```
ggAcf(aelec, lag=48)
```

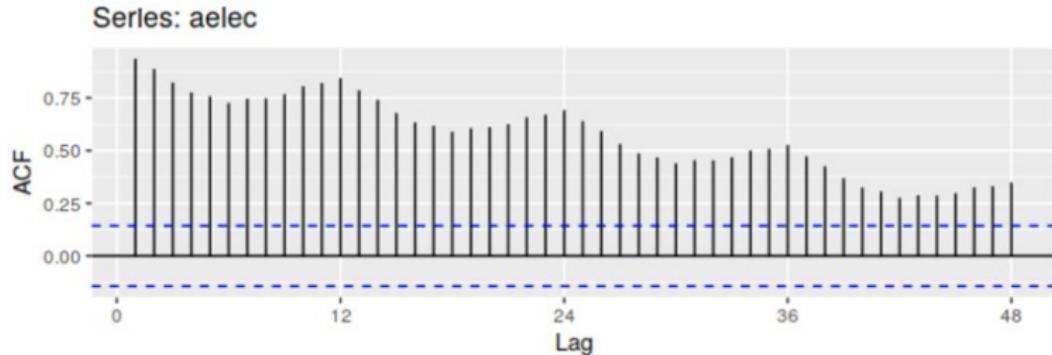


Figura 2.16: ACF de la demanda mensual de electricidad en Australia.

Tendencia y Estacionalidad en ACF

```
ggAcf(aelec, lag=48)
```

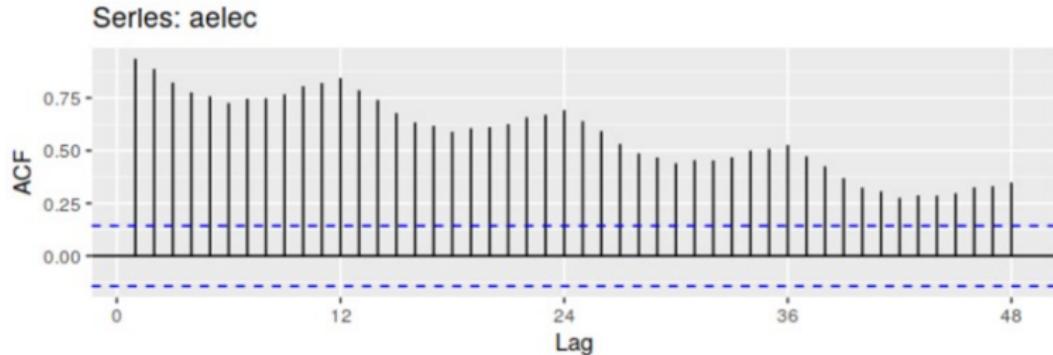


Figura 2.16: ACF de la demanda mensual de electricidad en Australia.

La lenta disminución en el ACF a medida que aumentan los retrasos se debe a la tendencia, mientras que la forma de “ondulación constante” se debe a la estacionalidad.

Contenido

1 Introducción

2 Gráficos de series de tiempo

3 Autocorrelación - ACF

4 Ruido Blanco

Ruido Blanco

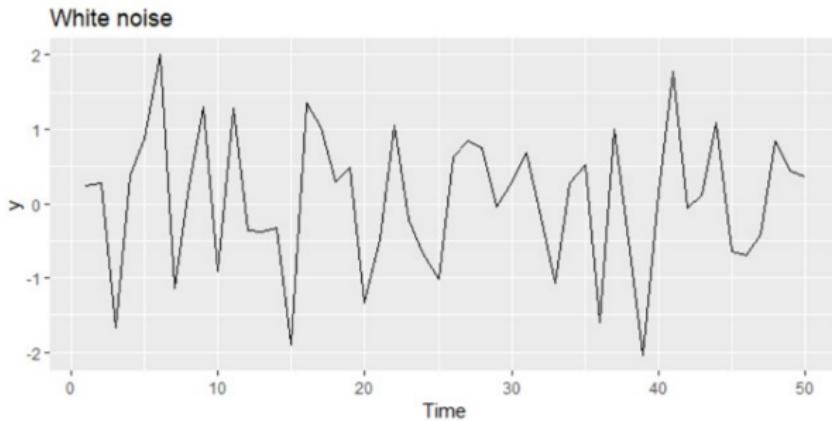
Las series de tiempo que no muestran autocorrelación se llaman **ruido blanco**

```
y <- ts(rnorm(50))  
autoplot(y) + ggtitle("White noise")
```

Ruido Blanco

Las series de tiempo que no muestran autocorrelación se llaman **ruido blanco**

```
y <- ts(rnorm(50))  
autoplot(y) + ggtitle("White noise")
```



Ruido Blanco

```
ggAcf(y)
```

Ruido Blanco

ggAcf(y)

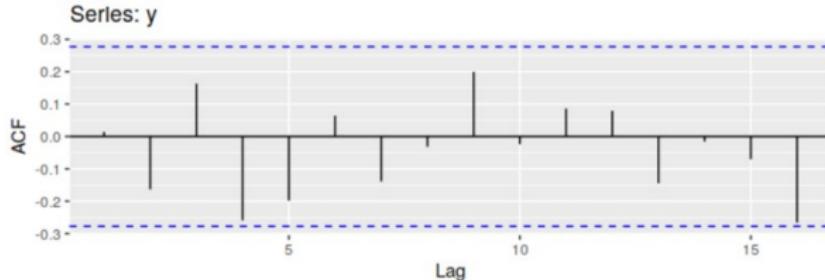


Figura 2.18: Función de autocorrelación para la serie de ruido blanco.

- Se espera que cada autocorrelación sea cercana a cero.
- No serán exactamente iguales a cero ya que hay alguna variación aleatoria.
- Esperamos que el 95 % de los picos en el ACF se encuentren dentro de los límites para la longitud de la serie de tiempo.

Preguntas?

Gracias!! ,

Jr.

orlando.joaqui@correounivalle.edu.co